Bài 4. Machine Learning

GV: TRẦN THỊ THU PHƯƠNG

KHOA: TOÁN- CNTT

Nội dung

1. Giới thiệu
2. Một số khái niệm
3. Các mô hình

1. Giới thiệu

- Machine Learning (ML): cho máy tính học từ dữ liệu & thống kê.
- ML là bước tiến hướng tới Trí tuệ nhân tạo (AI).
- Chương trình ML: phân tích dữ liệu và học để dự đoán kết quả.

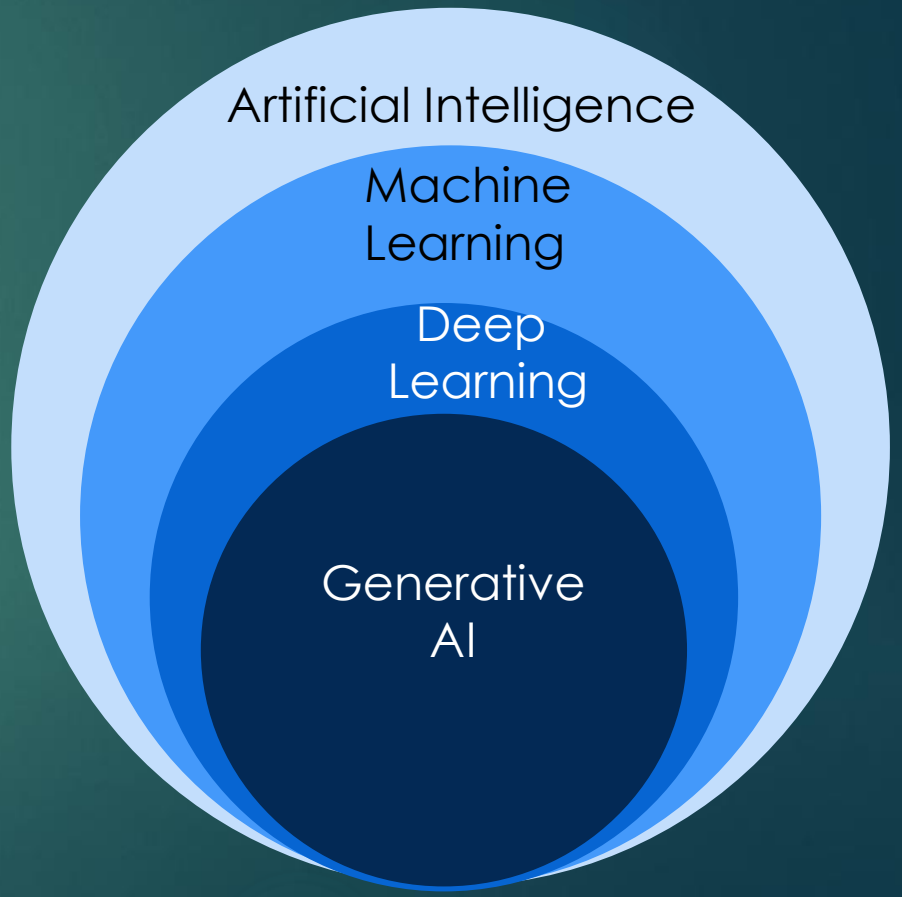

1. Giới thiệu: Dataset

- Với máy tính, data set là bất kỳ tập hợp dữ liệu: từ mảng đến cơ sở dữ liệu đầy đủ.
- Ví dụ mảng:[99, 86, 87, 88, 111, 86, 103, 87, 94, 78, 77, 85, 86]
- Ví dụ bảng:

Car name	Color	Age	Speed	AutoPass
BMW	red	5	99	Y
VW	white	7	88	Y
Ford	white	2	111	Y
Toyota	gray	12	77	N

- Mảng số: ước lượng giá trị trung bình, lớn nhất, nhỏ nhất...
- Bảng: thấy màu phổ biến (vd. white), tuổi cao nhất (vd. 17 năm).
- Câu hỏi thú vị: Có thể dự đoán AutoPass từ các cột khác không?
- Bài toán dự đoán = nhiệm vụ cốt lõi của ML.

Rút ra được gì từ dữ liệu

1. Giới thiệu: Kiểu dữ liệu

- Numerical (số)
  - Discrete (rời rạc): đếm, số nguyên.
  - Ví dụ: số xe đi qua.
  - Continuous (liên tục): đo lường, giá trị thực.
  - Ví dụ: giá tiền, kích thước.
- Categorical (phân loại)
  - Ví dụ: Màu sắc, Yes/No
- Ordinal (thứ bậc)
  - Ví dụ: Điểm xếp loại A>B>C

- ML thường làm việc với **tập dữ liệu rất lớn.**
- Phạm vị bài học có thể sử dụng dữ liệu nhỏ và vừa

2. Một số khái niệm: Mean, median, Mode

- Mean – Giá trị trung bình
- Median – Giá trị ở giữa dãy thứ tự
- Mode – Giá trị xuất hiện nhiều nhất

speed = [99,86,87,88,111,86,103,87,94,78,77,85,86]

- Mean= (99+86+87+88+111+86+103+87+94+78+77+85+86) / 13 = 89.77

```
import numpy

speed = [99,86,87,88,111,86,103,87,94,78,77,85,86]

x = numpy.mean(speed)

print(x)
```

2. Một số khái niệm: Mean, median, Mode

- Mean – Giá trị trung bình
- Median – Giá trị ở giữa dãy thứ tự
- Mode – Giá trị xuất hiện nhiều nhất

speed = [99,86,87,88,111,86,103,87,94,78,77,85,86]

77, 78, 85, 86, 86, 86, **87**, 87, 88, 94, 99, 103, 111

Median: 87

```
import numpy

speed = [99,86,87,88,111,86,103,87,94,78,77,85,86]

x = numpy.median(speed)

print(x)
```

2. Một số khái niệm: Mean, median, Mode

- Mean – Giá trị trung bình
- Median – Giá trị ở giữa dãy thứ tự
- Mode – Giá trị xuất hiện nhiều nhất

speed = [99,86,87,88,111,86,103,87,94,78,77,85,86]

77, 78, 85, 86, 86, 86, **87**, 87, 88, 94, 99, 103, 111
Median: 87

```
import numpy

speed = [99,86,87,88,111,86,103,87,94,78,77,85,86]

x = numpy.median(speed)

print(x)
```

If there are two numbers in the middle, divide the sum of those numbers by two.

```
77, 78, 85, 86, 86, 86, 87, 87, 94, 98, 99, 103
```

```
(86 + 87) / 2 = 86.5
```

2. Một số khái niệm: Mean, median, Mode

- Mean – Giá trị trung bình
- Median – Giá trị ở giữa dãy thứ tự
- Mode – Giá trị xuất hiện nhiều nhất

speed = [99,86,87,88,111,86,103,87,94,78,77,85,86]

99, 86, 87, 88, 111, 86, 103, 87, 94, 78, 77, 85, 86

Mode = 86

```
from scipy import stats

speed = [99,86,87,88,111,86,103,87,94,78,77,85,86]

x = stats.mode(speed)

print(x)
```

2. Một số khái niệm: Standard Deviation

- Standard Deviation: Độ lệch chuẩn (σ) đo mức độ phân tán của dữ liệu quanh giá trị trung bình (mean).
- σ thấp → phần lớn giá trị gần mean.
- σ cao → giá trị rải rộng trên khoảng lớn hơn.

Dữ liệu: speed = [86, 87, 88, 86, 87, 85, 86]

Mean ≈ 86.4

Standard deviation (σ) ≈ 0.9

Diễn giải: Đa số tốc độ nằm gần 86.4 trong khoảng xấp xỉ ±0.9.

```
import numpy

speed = [86,87,88,86,87,85,86]

x = numpy.std(speed)

print(x)
y = numpy.var(speed)

print(y)
```

- Phương sai (Variance) là đại lượng khác cho biết mức độ phân tán của các giá trị.
- Phương sai thực tế bằng trung bình các bình phương sai lệch và bằng σ^2

2. Một số khái niệm: Percentiles

- Percentile: mốc giá trị mà p% quan sát nhỏ hơn hoặc bằng mốc đó.Ví dụ: P75 = 43 nghĩa là 75% người có tuổi ≤ 43.
- Median (P50) = trung vị.
- Quartiles: Q1 = P25, Q2 = P50, Q3 = P75.IQR = Q3 − Q1 (đo độ phân tán, chống nhiễu tốt hơn độ lệch chuẩn với dữ liệu lệch).

```
import numpy

ages =
[5,31,43,48,50,41,7,11,15,39,80,82,32,2,8,6,
25,36,27,61,31]

x = numpy.percentile(ages, 75)

print(x)
```

Machine learning: Linear Regression (hồi quy tuyến tính)

Hồi quy tuyến tính

- Hồi quy: Sử dụng khi muốn tìm mối quan hệ giữa các biến
- Mối quan hệ này dùng để dự báo giá trị trong tương lai.

- Ta mô hình hóa quan hệ giữa đặc trưng $\mathbf{x} \in \mathbb{R}^p$ và mục tiêu y bằng:

$$\hat{y} \approx \mathbf{w}^\top \mathbf{x} + b$$

trong đó $\mathbf{w}$ là vector hệ số (độ dốc theo từng đặc trưng), b là hệ số chặn.

- Hệ số được ước lượng bằng cách **tối thiểu hóa MSE** (mean squared error):

$$\mathrm{MSE} = \frac{1}{n} \sum_{i=1}^{n} \left(y_i - (\mathbf{w}^\top \mathbf{x}_i + b)\right)^2.$$

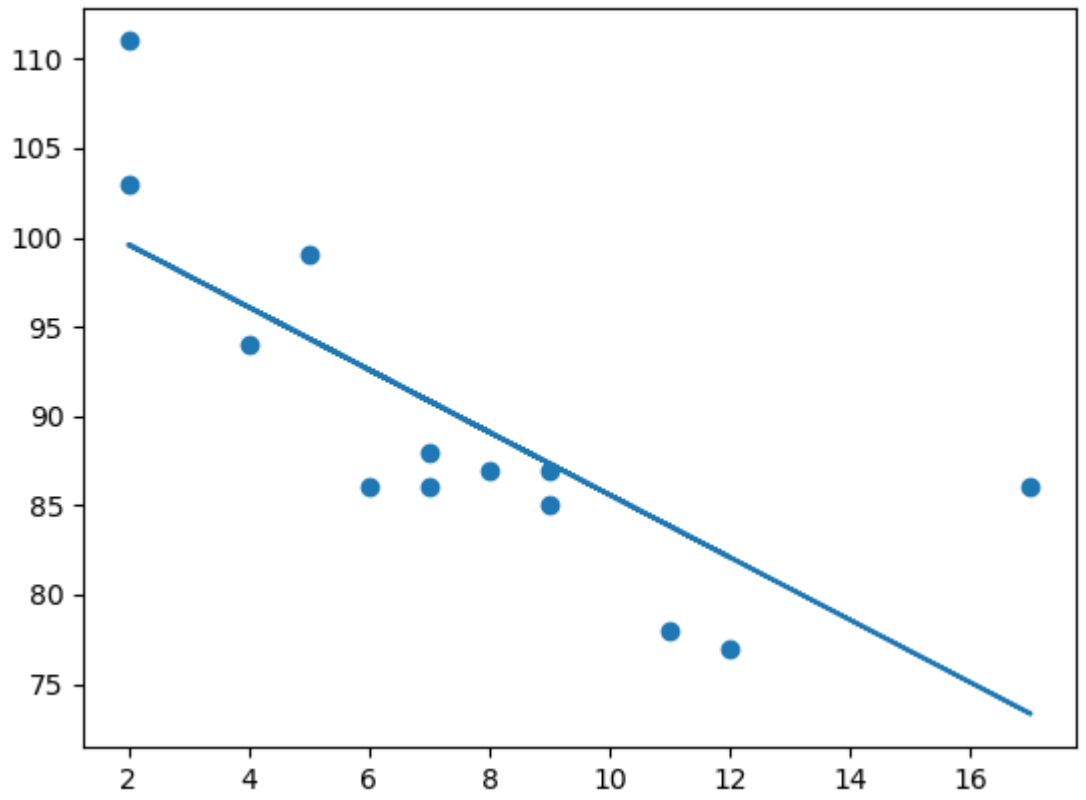

Hồi quy tuyến tính: như thế nào

- Ví dụ tìm mối quan hệ giữa số tuổi xe và tốc độ của xe
- x = [5,7,8,7,2,17,2,9,4,11,12,9,6]
  y
  = [99,86,87,88,111,86,103,87,94,78,77,85,86]
- Có nhận xét gì giữa 2 đại lượng này?

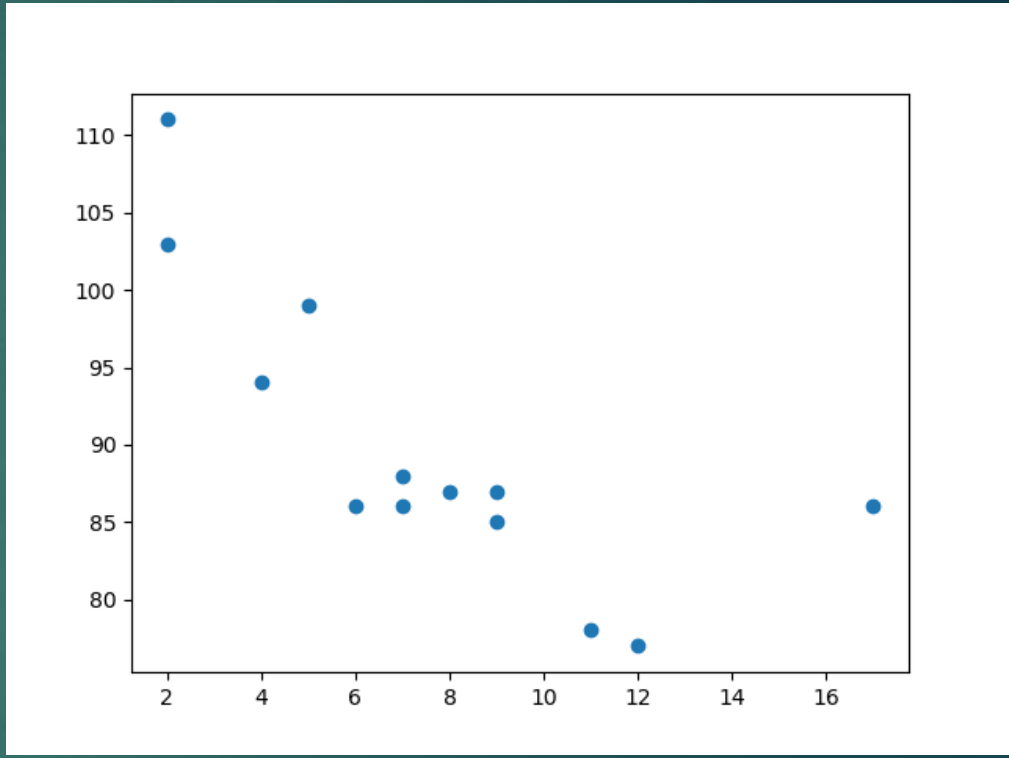


```
import matplotlib.pyplot as plt

x = [5,7,8,7,2,17,2,9,4,11,12,9,6]
y = [99,86,87,88,111,86,103,87,94,78,77,85,86]

plt.scatter(x, y)
plt.show()
```

Linear Regression: Python


```
import matplotlib.pyplot as plt
from scipy import stats
x =
[5,7,8,7,2,17,2,9,4,11,12,9,6]
y
=[99,86,87,88,111,86,103,87,94,7
8,77,85,86]
slope,intercept, r,
p,std_err=stats.linregress(x, y)
def myfunc(x):
  return slope * x + intercept
mymodel = list(map(myfunc, x))
plt.scatter(x, y)
plt.plot(x, mymodel)
plt.show()
```

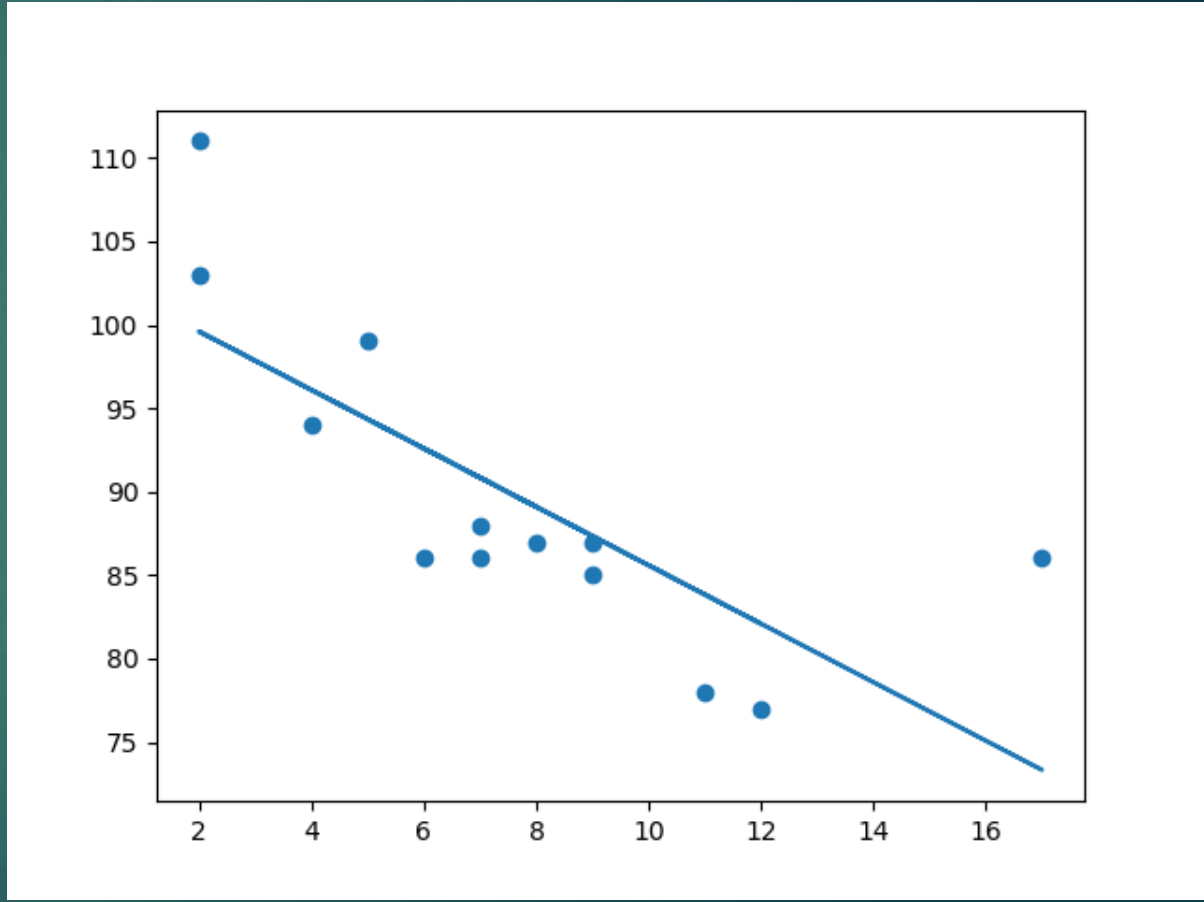

Dự báo giá trị

- Dự báo tốc độ của xe có tuổi đời là 10 năm

```
from scipy import stats
x = [5,7,8,7,2,17,2,9,4,11,12,9,6]
y =[99,86,87,88,111,86,103,87,94,78,77,85,86]
slope, intercept, r, p, std_err = stats.linregress(x, y)
def myfunc(x):
  return slope * x + intercept
speed = myfunc(10)
print(speed)
```

Kết quả trả về là 85.6

Các đại lượng đo lường

- R nằm trong khoảng -1 đến 1. Một giá trị gần -1 cho thấy mối tương quan nghịch mạnh, giá trị gần 1 cho thấy mối tương quan thuận mạnh và giá trị gần 0 cho thấy mối tương quan yếu hoặc không có tương quan.
- Trong ví dụ trên, r = -0.76, cho thấy có mối tương quan nghịch giữa tuổi và tốc độ của xe.

```
=== CHỈ SỐ ĐÁNH GIÁ (tính TRONG MẪU do dữ liệu nhỏ) === Hệ số tương quan Pearson r: -0.758592 R^2 (trong mẫu): 0.575461 (kiểm tra: r^2 ≈ 0.575461) MAE (trong mẫu): 4.939945 RMSE (trong mẫu): 6.032393 Slope (hệ số dốc): -1.751288 Intercept (hệ số chặn): 103.105960 p-value (kiểm định b=0): 0.00264687 SE(slope): 0.453536
```

Giả sử y_i là giá trị thật, $\hat{y}_i$ là dự đoán, n là số mẫu.

- **MAE (Mean Absolute Error)** — sai số tuyệt đối trung bình

$$\mathrm{MAE} = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|$$

→ Dễ diễn giải (đơn vị như y), ít nhạy với ngoại lai hơn RMSE.

- **RMSE (Root Mean Squared Error)** — căn bình phương sai số trung bình

$$\mathrm{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}$$

→ Phạt lỗi lớn nặng hơn; thường dùng để so sánh mô hình.

- R^2 **(Hệ số xác định)** — tỷ lệ phương sai của y được mô hình giải thích

$$R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}$$

(với $\bar{y}$ là trung bình của y). Trong hồi quy **đơn** có **intercept**, **trong mẫu**: $R^2 = r^2$.

- r **(hệ số tương quan Pearson)** — mức độ tuyến tính giữa x và y

$$r = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_i (x_i - \bar{x})^2}\sqrt{\sum_i (y_i - \bar{y})^2}}$$

Nằm trong $[-1, 1]$. Với hồi quy đơn + intercept, **trong mẫu**: $R^2 = r^2$.

Các đại lượng đo lường ví dụ dự báo tốc độ xe

=== CHỈ SỐ ĐÁNH GIÁ (tính TRONG MẪU- toàn bộ dữ liệu hiện có do dữ liệu nhỏ, thực tế phải tính trên bộ test) ===

- Hệ số tương quan Pearson r: -0.758592
- R^2 (trong mẫu): 0.575461 (kiểm tra: r^2 ≈ 0.575461)
- MAE (trong mẫu): 4.939945
- RMSE (trong mẫu): 6.032393
- Slope (hệ số dốc): -1.751288
- Intercept (hệ số chặn): 103.105960
- p-value (kiểm định b=0): 0.00264687
- Độ lệch chuẩn: SE(slope): 0.453536

Hồi quy tuyến tính: Bad Fit

x = [89,43,36,36,95,10,66,34,38,20,26,29,48,64,6,5,36,66,72,40]

y = [21,46,3,35,67,95,53,72,58,10,26,34,90,33,38,20,56,2,47,15]

r=0.01331814154297491

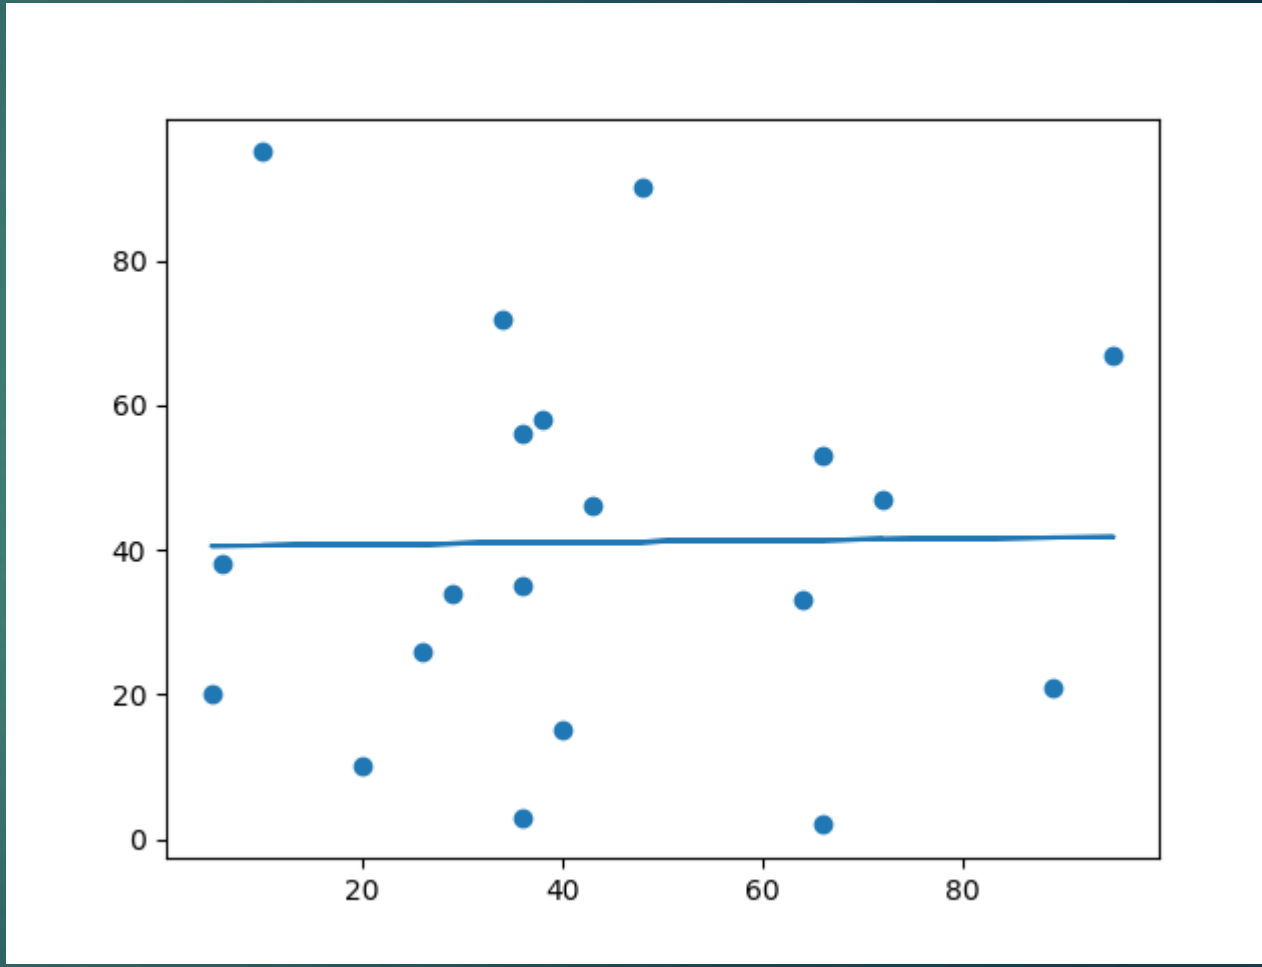

Bài tập

- Sử dụng hồi quy tuyến tính để dự báo giá nhà trên bộ dữ liệu được mô tả sau:
  The California housing dataset — Scikit-learn course

  Các công việc cần thực hiện:

  1. Báo cáo tổng quan dữ liệu
  2. Làm chuẩn dữ liệu (nếu có)
  3. Chia train/test (80/20, random_state=42).
  4. Sử dụng huấn luyện bằng LinearRegression.
  5. Báo cáo MAE, RMSE, R^2, r.
  6. Nhận xét kết quả và mô hình.